Lab1 预处理 实验报告

10152130122 钱庭涵

preprocess.py

主函数中, 创建需要用到的文件夹。

xml_form 中存放原 query/document 文件修改成 xml 格式后的文件, 这个文件夹只是个暂存文件夹,预处理完毕后会删除。

Answer 文件夹中对应存放 query 和各种类型的 document 文件预处理后的结果。

```
if (not (os.path.exists('./xml_form'))):
          os.mkdir('./xml_form')
      if (not (os.path.exists('./Answer'))):
          os.mkdir('./Answer')
      if (not (os.path.exists('./Answer/query'))):
          os.mkdir('./Answer/query')
      if (not (os.path.exists('./Answer/document'))):
    os.mkdir('./Answer/document')
      if (not (os.path.exists('./Answer/document/AP'))):
          os.mkdir('./Answer/document/AP')
      if (not (os.path.exists('./Answer/document/DOE'))):
178
          os.mkdir('./Answer/document/DOE')
179
      if (not (os.path.exists('./Answer/document/FR'))):
          os.mkdir('./Answer/document/FR')
      if (not (os.path.exists('./Answer/document/WSJ'))):
          os.mkdir('./Answer/document/WSJ')
      if (not (os.path.exists('./Answer/document/ZIFF'))):
          os.mkdir('./Answer/document/ZIFF')
```

读取 query 文件。

```
file1 = open('./query&document/topics.151-200', 'r')
Query_Lines = file1.read()
file1.close()
```

将 query 文件转换成 xml 格式的文件。

```
191 change_query_form(Query_Lines)
```

跳转到 change_query_form 函数,创建并打开 topics.xml 文件,先写入一个根元素,再在 QueryLines 中对应加上其他子元素的结尾,query 文件的格式比较统一,每个文件都有一对<top></top>根元素,并有这样的子元素:一个<num>、一个<title>、一个<desc>、一个<num>、(按顺序出现),因此使用字符串的 replace 函数,给对应的子元素加上结尾标志,再写入文件中,最后写入根元素的结尾。

跳转回主函数,对 xml 格式的 query 文件进行预处理, query_num 列表中存放 query 中各个子文件的名称。

```
192 query_num = []
193 query_process()
```

跳转到 query_process 函数,调用 xml.etree.ElementTree 模块,用 xml 文件的方式打开 query 文件,num 列表中存放每个子文件的名称,同理,title、desc、narr 列表中存放每个子文件的 title、desc、narr。

使用 findall 的方式找到所有 top 标签,在每个标签中,寻找一个子标签 num,获取该标签的文本,存入 num 列表,再去除该文本前后的空行、"Number:"、空格,得到该子文件的标题,添加到 query_num 列表中。

然后在每个 top 标签中,寻找一个子标签 title,获取该标签的文本,存入 title 列表,desc 和 narr 同理。

```
def query_process():
    root = ET.parse('./xml_form/topics.xml')
    num = []
    title = []
    desc = []
    narr = []
    for file in root.findall('top'):
        i = file.find('num').text
        num.append(i)
        temp = i.strip('\n').replace('Number:', '').strip(' ')
        query_num.append(temp)
        title.append(file.find('title').text)
        desc.append(file.find('desc').text)
        narr.append(file.find('narr').text)
```

对各列表中的文本进行预处理、存入新的列表中。

```
74     stem_num = pre_process(num)
75     stem_title = pre_process(title)
76     stem_desc = pre_process(desc)
77     stem_narr = pre_process(narr)
```

跳转到 pre_process 函数, word_stem_list 是返回的预处理后的文本列表, 遍历 word_list 中的的文本, 进行一系列处理(全部转换成小写字母, 词条化, 去除停用词, 词性归并, 词干还原, 去除大部分无用符号), 再添加到 word_stem_list 列表中。

词干还原采用 porter 算法,调用写好的 **porter.py** 来实现。 返回的预处理后的文本列表。

回到 query_process 函数,使用 findall 的方式找到所有 top 标签,在每个标签中,寻找一个子标签 num,将预处理后的文本对应放入该 num 子标签的文本中, title、desc、narr 同理,最后再将文件写回到 query 文件中。

```
j = 0
for file in root.findall('top'):
    elem = file.find('num')
    elem.text = stem_num[j]
    elem = file.find('title')
    elem.text = stem_title[j]
    elem = file.find('desc')
    elem.text = stem_desc[j]
    elem = file.find('narr')
    elem.text = stem_narr[j]
    j += 1
    root.write('./xml_form/topics.xml')
```

跳转回主函数,开始切分 query 文件。

195 query_depart()

跳转到 query_depart 函数,打开并读入预处理后的 query 文件,对于每行,先去掉换行符,得到 temp1 字符串,然后进行 if 判断。

如果 temp1 是'<top>', 说明是一个子文件的开始, 标记 start 为 1, 根据 query_num 列表中的标题打开并创建一个 xml 文件。

如果 start 为 1, 说明 xml 文件已经创建并打开, 可以开始写入读取的行。

如果 temp1 是'</top>', 说明到达一个子文件的结尾(此时元素的结尾标志也已经写入

了),关闭文件,print 对应的成功标志,标记 start 为 0,表示文件写入停止。

最后删除已经无用处的 xml 格式的 query 文件, 节约内存。

```
def query depart():
          file = open('./xml_form/topics.xml', 'r')
          Lines = file.readlines()
          file.close()
94
          k = 0
          start = 0
          for line in Lines:
              temp1 = line.strip('\n')
              if temp1 == '<top>':
                  start = 1
100
                  file = open('./Answer/query/Topic' + query_num[k] + '.xml', 'w')
              if start == 1:
                  file.write(line)
103
              if temp1 == '</top>':
104
                  file.close()
105
                  print('Topic_' + query_num[k] + ' succeed')
106
                  start = 0
                  k += 1
          os.remove('./xml form/topics.xml')
```

跳转回主函数,创建 path 列表,添加所有 document 文件所在的文件夹路径。

```
path = []
path.append('./query&document/disk12/disk1/AP')
path.append('./query&document/disk12/disk2/AP')
path.append('./query&document/disk12/disk1/DOE')
path.append('./query&document/disk12/disk1/WSJ')
path.append('./query&document/disk12/disk2/WSJ/1990')
path.append('./query&document/disk12/disk2/WSJ/1991')
path.append('./query&document/disk12/disk2/WSJ/1992')
path.append('./query&document/disk12/disk1/ZIFF')
path.append('./query&document/disk12/disk2/ZIFF')
path.append('./query&document/disk12/disk1/FR')
path.append('./query&document/disk12/disk1/FR')
path.append('./query&document/disk12/disk2/FR')
```

创建 elem_type 列表,添加不同种类 document 文件中,需要删除的子标签列表。

遍历 path 路径,调用 os.walk 模块遍历路径中的每一个文件,获取当前文件的文件名。如果当前文件不是 README.gz,则为有效的 document 文件,开始进行处理。调用 gzip 模块,直接打开该文件压缩包,读取其所有内容,

```
for count in range(len(path)):

for a in os.walk(path[count]):

document_files = a[2]

for document_file in document_files:

if document_file != 'README.gz':

file2 = gzip.GzipFile(path[count] + '/' + document_file, 'r')

document_lines = file2.read()

file2.close()

document_file_name = document_file.replace('.gz', '')
```

将当前读入的 document 文件转换成 xml 格式。

```
change_document_form(document_lines, document_file_name)
```

跳转到 change_document_form 函数,创建并打开当前 document 文件的 xml 格式文件,先写入根元素,然后调用 chardet 模块,获取当前 document 文件的编码类型,根据不同编码类型,使用不同的方式,将当前 document 文件的内容改用 utf-8 编码,然后进行类型判断:

在五种 document 文件中 (AP、DOE、WSJ、ZF、FR) 中, AP、DOE 和 WSJ 种类 document 的<TEXT>标签中不存在嵌套子标签,因此可以将文件中影响 xml 格式的'&'符号去掉之后,直接写入 xml 格式文件。

在 ZF 种类 document 中, <TEXT>标签中嵌套有<ABSTRACT>子标签, 因此除了去掉'&'符号之外, 还去掉<ABSTRACT>和</ABSTRACT>这一对子标签, 再写入 xml 格式文件。

在 FR 种类 document 中, <TEXT>标签中嵌套有多种类型子标签, 因此先去掉'&'符号, 再将需要用到的标签 (包括在 elem_type 列表中记录的需要删除的标签) 替换成不含'<>'字符的独一无二的纯文本, 然后调用 re 模块去除读入内容中所有'<>'及其内部的字符串, 这样就去掉了嵌套的多种类型子标签, 再将之前替换的纯文本替换为带'<>'的标签, 最后写入xml 格式文件。

最后再写入根元素的结尾。

```
def change_document_form(DocumentLines, type):
    fp = open('./xml_form/' + type + '.xml', 'w')
22
23
24
           fp.write('<document>\n\n')
           strCodingFmt = chardet.detect(DocumentLines)['encoding']
           if strCodingFmt == 'ISO-8859-1':
               lines_tmp = DocumentLines.decode('utf-8', 'ignore')
           lines_tmp = DocumentLines.decode()
if type[:2] == 'ZF':
               fp.write(lines_tmp.replace('&', '').replace('<ABSTRACT>', '\n').replace('</ABSTRACT>', '\n'))
           elif type[:2] == 'FR':
               lines_tmp1 = lines_tmp.replace('&', '').replace('<DOC>', '(Document_FR_DOC1)')\
               '</DOC>')\
                    .replace('(Document_FR_DOCNO1)', '<DOCNO>').replace('(Document_FR_DOCNO2)', '</DOCNO>')\
.replace('(Document_FR_DOCID1)', '<DOCID>').replace('(Document_FR_DOCID2)', '</DOCID>')\
.replace('(Document_FR_TEXT1)', '<TEXT>').replace('(Document_FR_TEXT2)', '</TEXT>')
               fp.write(lines_tmp3)
               fp.write(lines_tmp.replace('&', ''))
           fp.write('\n</document>\n\n')
           fp.close()
```

跳转回主函数的 for 循环内,判断 document 文件的类型,对于不同的文件,使用不同的列表处理。

如 AP 类型的 document 文件,AP_title 存放所有当前文件的子文件的标题,elem_type 列表则取对应的 AP 类型 document 中需要删除的子标签列表,document_depart 函数的最后一个参数为子文件应存放的文件夹名,即'AP'。

DOE、WSJ、ZF、FR 同理。

```
document_file[:2]
234
                          AP_title = []
                          document_process(document_file_name, AP_title, elem_type[0])
                      document_depart(document_file_name, AP_title, 'AP')
if document_file[:3] == 'DOE':
                          DOE_title = []
                          document_process(document_file_name, DOE_title, elem_type[1])
                          document_depart(document_file_name, DOE_title, 'DOE')
                      if document_file[:3] == 'WSJ':
                          WSJ_title = []
                          document_process(document_file_name, WSJ_title, elem_type[2])
                          document_depart(document_file_name, WSJ_title, 'WSJ')
                      if document_file[:2] == 'ZF':
                          ZF_title = []
                          document_process(document_file_name, ZF_title, elem_type[3])
                          document_depart(document_file_name, ZF_title,
                      if document_file[:2] == 'FR':
                          FR_title = []
                          document_process(document_file_name, FR_title, elem_type[4])
                          document_depart(document_file_name, FR_title, 'FR')
```

跳转到 document_process 函数,调用 xml.etree.ElementTree 模块,用 xml 文件的方式打开 document 文件,DOCNO 列表中存放每个子文件的名称,TEXT 列表中存放每个子文件中有用的文本。

使用 findall 的方式找到所有 DOC 标签,在每个标签中,寻找一个子标签 DOCNO,获取该标签的文本,存入 DOCNO 列表,再去除该文本前后的空行和空格,得到该子文件的标题,添加到 title_list 列表中。

然后寻找所有 TEXT 标签,获取该标签的文本,存入 temp2 列表。

如果 temp2 列表不为空,则按照一个换行符作为间隔,将 temp2 列表中所有字符串连接在一起,并添加到 TEXT 列表中。

如果 temp2 列表为空,则将一个换行符添加到 TEXT 列表中。

再根据 remove_list, 寻找所有需要删除的子标签, 并删除该子元素。

```
def document_process(type, title_list, remove_list):
          root = ET.parse('./xml_form/' + type + '.xml')
          DOCNO = []
113
          TEXT = []
for file in root.findall('DOC'):
              i = file.find('DOCNO').text
              DOCNO.append(i)
              temp = i.strip('\n').strip(' ')
              title_list.append(temp)
              temp2 = [f.text for f in file.findall('TEXT')]
              if temp2 != [None]:
                  TEXT.append('\n'.join(temp2))
122
123
124
                 TEXT.append('\n')
125
              for remove elem in remove list:
                  for k in file.findall(remove elem):
126
                       file.remove(k)
```

对 DOCNO 和 TEXT 列表中的文本进行预处理,存入新的列表中。

```
stem_DOCNO = pre_process(DOCNO)
stem_TEXT = pre_process(TEXT)
```

使用 findall 的方式找到所有 DOC 标签,在每个标签中,寻找一个子标签 DOCNO,将 预处理后的文本对应放入该 DOCNO 子标签的文本中。

在每个标签中,寻找所有 TEXT 子标签,如果对应的预处理后的文本为空,则将一个空格字符放入该子标签的文本中,并跳出循环。

如果对应的预处理后的文本不为空,根据标记 i 判断当前 TEXT 子标签是不是寻找到的 第一个 TEXT 子标签,如果是,就将对应的预处理后的文本放入该子标签的文本中,并将 i 标记为 1;如果不是,说明对应的预处理后的文本已经放好了,因此删除该子元素。

最后再将文件写回到对应的 document 文件中。

```
for file in root.findall('DOC'):
132
               elem = file.find('DOCNO')
134
               elem.text = stem_DOCNO[j]
               for elem in file.findall('TEXT'):
136
                    if stem_TEXT[j] == '':
    elem text = ' '
                        elem.text =
138
139
                    if i != 0:
140
                        file.remove(elem)
141
142
143
                        elem.text = stem_TEXT[j]
                        i = 1
               j += 1
          root.write('./xml_form/' + type + '.xml')
```

跳转到 document_depart 函数,打开并读入预处理后的 document 文件,对于每行, 先去掉换行符,得到 temp1 字符串,然后进行 if 判断。

如果 temp1 是'<DOC>', 说明是一个子文件的开始, 标记 start 为 1, 根据 folder_name 和 title list 列表中的标题打开并创建一个 xml 文件。

如果 start 为 1, 说明 xml 文件已经创建并打开, 可以开始写入读取的行。

如果 temp1 是'</DOC>',说明到达一个子文件的结尾(此时元素的结尾标志也已经写入了),关闭文件,print 对应的成功标志,标记 start 为 0,表示文件写入停止。

最后删除已经无用处的 xml 格式的 document 文件,节约内存。

```
def document_depart(type, title_list, folder_name):
    file = open('./xml_form/' + type + '.xml', 'r')
           Lines = file.readlines()
           file.close()
           start = 0
            for line in Lines:
154
                temp1 = line.strip('\n')
                if temp1 == '<DOC>':
                    start = 1
                file = open('./Answer/document/' + folder_name + '/' + title_list[k] + '.xml', 'w')
if start == 1:
                    file.write(line)
                if temp1 == '</DOC>':
                     file.close()
                     print(title list[k] + ' succeed')
164
                     start =
                     k += 1
           os.remove('./xml_form/' + type + '.xml')
```

跳转回主函数的 for 循环外,此时所有 query 和 document 文件都已经预处理并切分完毕,删除已经无用的 xml_form 文件夹,完成 lab1 的预处理。

255 os.rmdir('./xml_form')

Result:

最后得到的 Answer 文件夹中,含有 query 和 document 两个子文件夹。
document
query
query 文件夹中存放 query 的所有预处理并切分的结果。
名称
Topic_151
Topic_152
Topic_153
Topic_154
Topic_155
Topic_156
Topic_157
Topic_158
Topic_159 Topic_160
Topic_161
Topic_162
Topic_163
Topic_164
Topic_165
Topic_166
Topic_168
☐ Topic_172

document 文件夹中含有 AP、DOE、FR、WSJ、ZIFF 五个子文件夹,分别存放不同类型 document 的所有预处理并切分的结果。

AP DOE FR WSJ ZIFF				
名称	名称	呂称	名称	名称
AP880212-000	1 DOE1-01-000	1 FR88101-0001	WSJ861201-000	1 TF107-804-004
AP880212-000	DOE1-01-000	2 FR88101-0002	WSJ861201-000	2 ZF107-804-068
AP880212-000	3 DOE1-01-000	3 FR88101-0003	WSJ861201-000	3 TF107-804-098
AP880212-000	4 DOE1-01-000	4 FR88101-0004	WSJ861201-000	4 📄 ZF107-804-694
AP880212-000	5 📄 DOE1-01-000	5 FR88101-0005	WSJ861201-000	5 ZF107-804-892
AP880212-000	6 DOE1-01-000	6 FR88101-0006	WSJ861201-000	6 ZF107-804-948
AP880212-000	7 DOE1-01-000	7 FR88101-0007	WSJ861201-000	7 TF107-805-020
AP880212-000	8 DOE1-01-000	8 FR88101-0008	WSJ861201-000	8 📄 ZF107-805-128
AP880212-000	9 🗎 DOE1-01-000	9 FR88101-0009	WSJ861201-000	9 📄 ZF107-805-178
AP880212-001	0 DOE1-01-001	0 FR88101-0010	WSJ861201-001	0 📄 ZF107-805-190
AP880212-001	1 DOE1-01-001	1 FR88101-0011	WSJ861201-001	1 📄 ZF107-805-316
AP880212-001	2 DOE1-01-001	2 FR88101-0012	WSJ861201-001	2 TF107-805-332
AP880212-001	3 DOE1-01-001	3 FR88101-0013	WSJ861201-001	3 📄 ZF107-805-340
AP880212-001	4 DOE1-01-001	4 FR88101-0014	u 📄 WSJ861201-001	4 📄 ZF107-805-368
AP880212-001	5 DOE1-01-001	5 FR88101-0015	WSJ861201-001	5 📄 ZF107-805-426
AP880212-001	6 DOE1-01-001	6 FR88101-0016	WSJ861201-001	6 ZF107-805-462
AP880212-001	7 DOE1-01-001	7 FR88101-0017	WSJ861201-001	7 📄 ZF107-805-474
AP880212-001	8 DOE1-01-001	8 FR88101-0018	WSJ861201-001	8 TF107-805-482
AP880212-001	9 DOE1-01-001	9 FR88101-0019	WSJ861201-001	9 TF107-805-492
AP880212-002	.0 📄 DOE1-01-002	0 FR88101-0020	WSJ861201-002	0 TF107-805-514
AP880212-002	_	1 FR88101-0021	WSJ861201-002	1 ZF107-805-548
AP880212-002	_			
AP880212-002	3 DOE1-01-002	3 FR88101-0023	WSJ861201-002	3 ZF107-805-576

提交的文件示例:

在提交文件时,为了注明这是哪个文件切分后的结果,命名的文件夹格式与上述得到的结果有些不同,增添了子文件夹,注明这是哪个磁盘哪个文件切分后的结果。

以下只取了 disk1 的 FR891013 作处理前和处理后的对比, 其他提交的文件请在 Answer 文件夹中查看。

处理前:

```
FR891013
     <D0C>
     <DOCNO> FR891013-0001 </DOCNO>
     <DOCID>fr.10-13-89.f2.A1000</DOCID>
     <TEXT>
     <FTAG tagnum=4700></FTAG>
     <ITAG tagnum=90>
     <T4>Federal Register</T4> / Vol. 54, No. 197 / Friday, October 13, 1989
     / Rules and Regulations
     <TAG tagnum=1>Vol. 54, No. 197 </ITAG>
     <ITAG tagnum=2>Friday, October 13, 1989 </ITAG>
     <ITAG tagnum=94>
     <ITAG tagnum=69>
     <TTAG tagnum=50>DEPARTMENT OF ENERGY</TTAG>
17
18
     <TTAG tagnum=18>Office of the Secretary</TTAG>
     <ITAG tagnum=52>10 CFR Part 600 </ITAG>
     <ITAG tagnum=52>Financial Assistance Rules; Revised Policy on Objective Merit Review
     of Discretionary Financial Assistance Applications </ITAG>
     <ITAG tagnum=10>
     <T2>AGENCY: </T2>Department of Energy.
     </ITAG>
     <TAG tagnum=10>
     <T2>ACTION: </T2>Final rule.
      </ITAG>
     <ITAG tagnum=10>
     < T2>SUMMARY: < T2>The Department of Energy today is revising subparts A and B of the Financial Assistance Rules, 10 CFR part 600, to establish
     standards for program offices to follow in conducting the objective merit
```

处理后部分文件:

FR891013-0001.xml

FR891013-0002.xml

| KOOC>
| COOCHOOFR891013 0003x/DOCHOO
| CTEXT>FR891013-0002xml | X | FR891013-0003xml | X |
| COOCHOOFR891013 0003x/DOCHOO
| CTEXT>Feder aviat administr faa dot final special condit special condit issu becom part type certif basi caproni vizzola costruzioni aeronautich s p a model c2zj seri airplan airplan novel unusu design featur compar state technolog envisag airworthi standard normal util acrobat communut categori airplan novel unusu design featur includ use advanc composit materi pressur fuel tank electron engin control system protect lightn high energi radio frequenc regul contain adequ appropri airworthi standard special condit contain addit safeti standard administr consid necessari establish level safeti equival provid applic airworthi standard novemb 13 1989 ervin dvorak aerospac engin standard offic ace 110 small airplan director aircraft certif servic central region feder aviat administr 601 east 12th street kansa citi missouri 64106 telephon 816 426 5688 juli 8 1983 caproni vizzola costruzioni aeronautich s p a vizzola ticino vares itali file applic faa brussel 's offic u s type certif model c2zj airplan made new applic u s type certif orctob 29 1986 caproni model c22j airplan mall two plac twin engin jet airplan maximum takeoff weight tip tank 2 767 pound two microturbo trs 18 turbojet engin instal side by sid fuselag aft cockpit airplan fulli aerobat maximum oper altitud 25 000 foot type certif basi caproni model c2zj airplan follow part 21 feder aviat regul far section 21 29 part 23 far effect februari 1 1964 includ amend 23 1 23 33 part 36 far effect decemb 1 1969 amend amend 36 1 amend effect date type certif fara 27 effect februari 1 1974 amend amend 27 2 27 5 exempt special condit adpropri issu accord section 11 49 public notic requir section section 11 28 11 29 b effect octob 14 1980 becom part type certif basi provid section 21 17 2 propos type design caproni model c22j airplan model aczy airworthi standard part 23 contain adequ appropri safeti standard novel unusu design featur model c22